


이 도구가 푸는 문제는 둘이다. ① **승인된 계획이 중간에 조용히 멈추는 것**. ② **구현은 끝났는데 리뷰 결과가 반영되지 않는 것**. 둘 다 사람의 규율에 맡기면 반복해서 새기 때문에, 판정을 **훅**에 담아 턴이 끝나는 것을 거부한다. 집행은 **규율이 아니라 구조다**.

01 전체 흐름 — 명령 셋과 집행 지점

UserPromptSubmit 훅 — 매 턴



진한 상자 = 사람이 부르는 명령 · 점선 상자 = 상태 파일(프로젝트의 `.claude/`에 남는다) · 주황 = 매 턴 훅 · 회색 = 종료 시 훅

02 완주 훅이 왜 돌인가

도구 훅 — 하네스의 할 일 목록을 본다

모델이 만든 마지막 할 일 목록에 미완료가 남았는지 확인한다. 목록을 세운 작업에는 정확하다.

파일 훅 — 파일을 본다

그 도구가 **아예 없는 세션**이 실제로 나왔다. 그때 도구 훅은 "계획을 안 세운 턴"으로 보고 조용히 통과한다 — 12단계 계획이 1단계만 하고 끝나도 잡히지 않는다. 파일 훅은 그 조건에서도 작동한다.


다단계 계획을 승인받으면 둘 중 하나는 반드시 남겨라. 한쪽이 못 보는 조건에서 다른 쪽이 본다 — 그것이 훅을 둘로 둔 유일한 이유다.

03 게이트가 지키는 원칙

원칙	왜
낡은 기록은 자동 만료	사용자가 새 지시를 준 뒤의 계획 파일은 지금 요청의 계획이 아니다. 계획 파일의 시각과 사람 발화 시각을 대조해 판별한다 — 지난주 잔재가 새 세션을 붙잡지 않는다.
판정 불가는 차단 유지	모르는 것을 근거로 게이트를 열면 게이트가 통째로 무력화된다. 소유자를 가릴 신호가 없으면 진단만 정확히 하고 열지는 않는다.
세션당 상한 8회	그 이상은 막지 않는다. 무한히 막는 게이트는 사람이 꺾고, 꺼진 게이트는 없는 게이트다.
훅이 고장 나면 통과	관측이 작업을 죽이면 안 된다. 게이트 자신의 오류로 일을 못 하게 되는 쪽이 미탐보다 나쁘다.
차단과 경고를 가른다	근거가 명확하면 차단(확정 결함 미해결), 판정이 애매하면 경고(리뷰 미실행). 거부하는 검사에서는 오탐 비용이 미탐보다 즉각적이다.

자기 리뷰는 측정상 나쁘다. 신선한 문맥의 리뷰어가 F1 28.6% 로 가장 높고, 자기 리뷰 24.6% · 의도까지 받은 리뷰 23.8% · 같은 세션 2회차 21.7% 순이다. 그래서 설계 원리는 하나다 — **리뷰어마다 받는 정보를 다르게 한다**. 근거 문헌이 프리프린트이므로 도구가 자기 라운드를 직접 측정해 쌓는다(→ 04).

01 한 라운드의 흐름



세 리뷰어는 공용 스키마 하나를 공유한다 — 필수 필드 `failure_scenario` (구체적 재현 경로를 못 쓰면 결함이 아니라 취향)와 `introduced_by_this_change` (false 면 남의 부채로 머지를 막지 않는다)가 오답을 억제한다.

02 자리와 모델은 다른 축이다

A·B·C 를 가르는 것은 받는 정보이지 모델이 아니다. 어느 모델이든 어느 자리에나 앉을 수 있고, 그 선택은 지시문이 아니라 **구성 파일**에서 한다 (지시문에 박으면 업데이트에 덮이고, 프로젝트마다 다른 예산을 표현할 수 없다). 프로젝트의 구성이 플러그인 기본을 이기고, 스크립트가 어느 쪽을 읽었는지 **출력한다** — 설정이 안 먹는데 먹는 것처럼 보이는 상태를 만들지 않는다.

03 줄일 때 무엇을 잃는가

자리	그 자리만 하는 일	빼면
A 계약 검증	구현자의 주장 검증	브리핑을 받지 않는 B 는 이 능력이 구조적으로 0 이다. 실측 라운드에서 주장 13건 중 3건이 거짓이었고(하나는 산술적으로 틀린 부등호) 그것을 잡은 자리다.
B 무편향	편향 없는 결함 사냥	측정된 오답률이 가장 낮았다. 줄이는 순서에서 마지막 이다.
C 교차 모델	규약을 공유하지 않는 눈	토큰은 아끼지만, 「우리 규약 때문에 못 보는 것」을 볼 가능성을 잃는다.
병합자	검증 · 기각	빼지 마라 . 실측 라운드의 기각 3건은 전부 「그대로 받았으면 코드를 나쁘게 만들었을 것」이었다.

교차 모델 리뷰는 대칭이 아니다. 다른 계열이 이쪽 코드를 리뷰하고 그 결과로 고친 조건은 문헌에서 **-8.6pp**(3 수정 / 13 회귀)였고, 반대 방향은 +18.1pp 였다. 그래서 **단독 발견을 확정 결함으로 직행시키지 않는다** — 병합자가 직접 코드를 열어 확인해야 확정이다.

04 리뷰어 자신을 재는 축 셋

라운드마다 자동

절제

이 리뷰어를 빼면 **놓쳤을** 확정 결함이 몇 건인가. 조합별 커버리지로 구성을 정한다.

사람만 채운다

정밀도

올린 것 중 몇 건이 실제 결함이었나. 라벨이 없으면 도구는 숫자를 **지어내지 않고** 「계산하지 않았다」고 말한다.

정답을 아는 diff

재현율

실사용 라운드로는 못詹다 — 「올린 것」만 보이므로 **있었는데 아무도 못 본 결함**은 그 숫자에 없다.

일괄 승인 플래그를 일부러 만들지 않았다. 모델이 정밀도 라벨을 채우면 병합자가 자기 판정을 자기가 채점하게 되고, 그러면 이 기록은 「리뷰가 잘 됐다」를 항상 말하는 장식이 된다. **부재가 통제다**.

회귀 케이스 17건 중 5건은 결함이 없는 대조군이고 정답은 「보고하지 않는 것」이다 — 없으면 「**전부 결함이라 답하는**」 리뷰어가 만점을 받는다. 게이트 자신에 12 스위트 269 검사, 각 스위트에 **사보타주 대조군**이 있다 — 대조군 없는 테스트는 근거가 아니다.